

Rapport du projet

Multimedia

Réaliser par : Djeghri Nabil 212131087206

Bourennane Tarek 212131090231

Spécialité : IL

Groupe : 2

Intitulé du Projet : Pipeline d'encodage vidéo MPEG-4
simplifié

Introduction :

La compression vidéo est aujourd'hui au cœur des systèmes multimédia modernes. Que ce soit pour le streaming, l'enregistrement ou le partage de vidéos, chaque flux visuel est généralement compressé afin de réduire l'espace de stockage et la bande passante nécessaire à sa transmission. Les codecs vidéo, tels que MPEG-4, remplissent cette fonction en transformant des images brutes en un flux binaire compact, puis en les reconstruisant à la lecture.

L'objectif de ce projet est de mettre en œuvre un pipeline d'encodage vidéo simplifié, inspiré de MPEG-4, entièrement en Python. À partir d'une séquence d'images au format PNG ou JPG, nous construisons un encodeur capable de produire un fichier binaire compressé (.bin), puis un décodeur permettant de restaurer les images originales.

Ce pipeline suit les étapes clés d'un codec vidéo réel :

- le prétraitement (conversion vers YCbCr et sous-échantillonnage de la chrominance) ;
- le codage intra-trame (I-frame) par DCT et quantification ;
- le codage inter-trame (P-frame) avec estimation de mouvement et calcul du résidu ;
- le codage entropique pour une compression sans perte ;
- enfin, l'évaluation des performances et la visualisation des résultats.

1. Description du Pipeline

Ce projet implémente un pipeline d'encodage/décodage vidéo de type MPEG-4 simplifié, écrit entièrement en Python. Le système compresse une séquence de frames d'images brutes en un fichier binaire compact, pouvant être décodé pour reconstruire les frames originales. Le pipeline comporte cinq étapes correspondant chacune à un composant clé d'un codec vidéo réel.




Figure 1 — Visualisation complète du pipeline MPEG-4 (les cinq étapes)

1.1 Pré-traitement (Partie 1)

Chaque frame BGR d'entrée est convertie dans l'espace colorimétrique YCbCr à l'aide des coefficients BT.601 : la canal de luminance Y est conservé à pleine résolution, tandis que les deux canaux de chrominance Cb et Cr subissent un sous-échantillonnage 4:2:0, réduisant leur résolution de moitié dans les deux directions. Cette étape exploite la moindre sensibilité de l'œil humain aux détails de couleur par rapport à la luminosité, réalisant immédiatement une réduction de 50 % des données chroma avec un impact perceptuel négligeable.

1.2 Codage Intra-frame — I-frames (Partie 2)

Les I-frames sont encodées sans référence à d'autres frames. Chaque canal est divisé en blocs 8×8 . Chaque bloc est décalé en niveau (-128), puis transformé par une DCT 2D de type II (normalisation orthonormale). Les coefficients fréquentiels obtenus sont divisés élément par élément par une matrice de quantification de type JPEG, puis arrondis à l'entier le plus proche.

La matrice de quantification pour la luminance utilise des pas plus grossiers aux hautes fréquences spatiales, là où la perception humaine est la moins sensible. Un facteur de qualité scalaire (QF) met à l'échelle la matrice entière : $QF > 1$ augmente la quantification (compression plus forte, qualité réduite), $QF < 1$ la diminue. Le décodage inverse l'opération par déquantification puis IDCT.

1.3 Codage Inter-frame — P-frames (Partie 3)

Les P-frames exploitent la redondance temporelle entre frames consécutives. La taille du Groupe d'Images (GOP) G détermine la fréquence des I-frames : les indices $0, G, 2G, \dots$ sont des I-frames, les autres sont des P-frames. Pour chaque P-frame :

- Le canal Y est divisé en macroblocs 16×16 .
- Une recherche exhaustive dans une fenêtre de $\pm S$ pixels trouve le meilleur macrobloc correspondant dans la frame de référence décodée (minimisation de la Somme des Différences Absolues, SAD).
- Le vecteur de mouvement résultant est stocké pour chaque macrobloc.
- Le résidu (différence entre le bloc courant et sa prédiction) est encodé par DCT et quantifié, exactement comme un canal I-frame.
- Les canaux chroma appliquent les mêmes vecteurs de mouvement mis à l'échelle par 0,5 pour tenir compte du sous-échantillonnage 4:2:0.

Le décodeur reconstruit chaque P-frame en appliquant les vecteurs de mouvement à la frame de référence, puis en ajoutant le résidu décodé.

1.4 Codage Entropique (Partie 4)

Après quantification, les tableaux de coefficients DCT et les vecteurs de mouvement sont sérialisés avec le protocole pickle de Python, puis compressés avec zlib (niveau 9). Un format conteneur binaire personnalisé est utilisé : un nombre magique de 4 octets (« MP4S »), suivi de blocs de métadonnées et de données de coefficients par frame, chacun préfixé d'un champ de longueur de 4 octets. Le décodeur lit, décompresse et déséréalise chaque bloc pour reconstruire exactement les mêmes structures de données qu'en sortie de l'encodeur.

1.5 Évaluation & Visualisation (Partie 5)

L'étape d'évaluation mesure le taux de compression (taille brute non compressée divisée par la taille du fichier .bin compressé) ainsi que le Rapport Signal-sur-Bruit de Crête (PSNR) par frame sur le canal Y. La visualisation produit une figure multi-panneaux couvrant : la séquence originale, la décomposition par canal, le pipeline DCT/quantification sur un bloc 8×8 , les vecteurs de mouvement superposés, et les cartes de résidus avec les frames reconstruites.

2. Choix de Conception & Justification

2.1 Espace Colorimétrique YCbCr et Sous-échantillonnage 4:2:0

Le choix de l'espace YCbCr est motivé par la séparation explicite de la luminance et de la chrominance. La vision humaine étant beaucoup plus sensible aux variations de luminosité qu'aux variations de couleur, le sous-échantillonnage 4:2:0 (réduction des canaux Cb et Cr d'un facteur 4 en surface) permet de réduire le volume de données dès la première étape sans perte perceptible notable.

La conversion est implémentée manuellement (sans appel à `cv2.cvtColor`) afin de garantir une transparence totale sur les coefficients utilisés et une compatibilité avec la chaîne de décodage.

2.2 DCT par Blocs 8×8 et Matrice de Quantification JPEG

L'utilisation de blocs 8×8 est un standard établi par JPEG et les normes MPEG. Ce compromis entre localité spatiale et efficacité de la transformée permet une implémentation simple tout en capturant l'essentiel de la redondance spatiale. La bibliothèque `scipy.fft.dctn` est utilisée avec normalisation orthonormée (`norm='ortho'`), garantissant des plages de valeurs numériquement stables.

La matrice de quantification est directement inspirée de la norme JPEG pour la luminance et la chrominance. Le facteur de qualité QF permet un contrôle précis du compromis taux/distorsion : un QF faible préserve la qualité au prix d'une compression moindre, tandis qu'un QF élevé maximise la compression au détriment de la fidélité.

2.3 Structure GOP et Macroblocs 16×16

Le choix d'une taille de macrobloc de 16×16 pixels pour l'estimation de mouvement est standard dans MPEG-2/4 : ce format offre suffisamment de contexte pour un appariement robuste tout en limitant le nombre de vecteurs à stocker. La fenêtre de recherche $\pm S$ (valeur par défaut : 8 pixels) équilibre la qualité de la prédiction et le coût de calcul de la recherche exhaustive.

La taille GOP G est un paramètre clé : $G=1$ signifie que chaque frame est une I-frame (pas d'inter-codage), tandis que G élevé maximise l'exploitation de la redondance temporelle. L'analyse expérimentale montre que $G=1$ atteint le meilleur taux de compression global, car les résidus des P-frames plus leurs vecteurs de mouvement occupent davantage d'espace que les I-frames pour des vidéos avec peu de mouvement.

2.4 Codage Entropique par zlib

Plutôt qu'implémenter un codage Huffman ou arithmétique sur mesure, nous utilisons zlib (algorithme DEFLATE) qui combine codage LZ77 et Huffman. Ce choix pragmatique offre d'excellentes performances de compression sur les données pickle sérialisées (tableaux numpy int16 avec de nombreux zéros après quantification), tout en restant simple et fiable. La séparation des métadonnées et des données de coefficients dans le fichier binaire facilite l'éventuelle lecture sélective des frames.

2.5 Format Binaire Personnalisé

Le format conteneur MP4S défini en Partie 4 offre : un nombre magique pour validation du format, une lecture des métadonnées globales (GOP, QF, nombre de frames) sans décompresser les données, et une granularité par frame permettant un accès séquentiel efficace. Ce design s'inspire des formats de conteneurs multimédia réels tels que MP4 ou MKV.

3. Analyse Expérimentale

Les expériences suivantes ont été conduites sur une séquence vidéo réelle composée de 11 frames représentant une scène extérieure avec mouvement modéré (cavalier dans un paysage ouvert). Les paramètres par défaut utilisés sont $QF = 1,0$ et $G = 8$ (sauf indication contraire), avec une fenêtre de recherche $S = 8$.

3.1 Qualité par Frame : PSNR (I-frames vs P-frames)

Le graphique ci-dessous présente le PSNR par frame pour un GOP de taille 8. Les frames 0 et 8 sont des I-frames (en bleu), les autres sont des P-frames (en orange). La moyenne globale est de 40,8 dB, ce qui correspond à une qualité visuelle bonne à très bonne selon les standards industriels (>37 dB).




Figure 2 — PSNR par frame (I-frames en bleu, P-frames en orange) — moyenne : 40,8 dB

On observe que les I-frames ont généralement un PSNR légèrement supérieur (environ 42–43 dB) car elles encodent directement toute l'information spatiale sans dépendance à une référence. Les P-frames voient leur PSNR décroître légèrement au fil du GOP (frames 4–7), ce qui est attendu : les erreurs de prédiction s'accumulent à mesure que l'écart temporel avec l'I-frame augmente. Ce phénomène de dérive temporelle est intrinsèque au codage inter-frame sans correction.

3.2 Taux de Compression vs Facteur de Quantification (QF)

Cette expérience fait varier le facteur QF de 0,5 à 5,0 avec un GOP fixe de $G = 8$. On mesure simultanément le taux de compression et le PSNR moyen du canal Y.




Figure 3 — Taux de compression et PSNR moyen en fonction du facteur de quantification QF

Les résultats montrent un comportement très classique en compression vidéo :

- Le taux de compression croît de manière quasi-linéaire avec QF, passant de ~25x à QF=0,5 à ~130x à QF=5.
- Le PSNR décroît en sens inverse, de ~46 dB à QF=0,5 à ~34 dB à QF=5.
- Les deux courbes se croisent autour de QF = 2, où le compromis taux/distorsion est équilibré (~65x de compression, ~38 dB PSNR).

Pour des applications où la qualité perceptuelle est prioritaire, $QF \leq 1$ est recommandé (PSNR > 42 dB). Pour des applications où la bande passante est le facteur limitant, $QF = 2-3$ offre un bon compromis.

QF	Taux de Compression	PSNR moyen (dB)	Observation
0,5	~25x	~46 dB	Haute qualité
1,0	~41x	~41 dB	Paramètre par défaut
2,0	~65x	~38 dB	Compromis équilibré
3,0	~89x	~36 dB	Compression élevée
5,0	~130x	~34 dB	Compression maximale

Tableau 1 — Synthèse du compromis taux de compression / qualité en fonction de QF

3.3 Taux de Compression vs Taille du GOP

Cette expérience fait varier la taille du GOP de G=1 à G=11 avec un QF fixe de 1,0, afin d'étudier l'impact de la fréquence des I-frames sur la compression globale.




Figure 4 — Taux de compression en fonction de la taille du GOP (G)

Contrairement à l'intuition initiale, les résultats montrent que le taux de compression diminue avec G. G=1 (uniquement des I-frames) atteint le meilleur taux de 47,0x, tandis que G=11 n'atteint que 39,5x.

Ce résultat s'explique par la nature du contenu vidéo utilisé :

- La scène présente peu de mouvement rapide, ce qui limite la redondance temporelle exploitable par les P-frames.
- Les P-frames stockent à la fois les vecteurs de mouvement et les résidus encodés ; pour des vidéos avec peu de mouvement, les résidus peuvent être plus volumineux que les coefficients d'une I-frame directe.
- Les I-frames bénéficient pleinement de la quantification et du codage entropique (nombreux zéros) sans le surcoût des vecteurs de mouvement.

Pour des vidéos avec un mouvement fort et répétitif (scènes de sport, panoramiques), on s'attendrait à la tendance inverse : les P-frames surpasseraient les I-frames en compression.

Taille GOP (G)	Nb I-frames	Nb P-frames	Taux de Compression
G=1	11	0	47,0x
G=2	6	5	43,5x
G=4	3	8	41,8x
G=8	2	9	40,2x
G=11	1	10	39,6x

Tableau 2 — Impact de la taille du GOP sur le taux de compression global

4. Conclusion

Ce projet a permis d'implémenter complètement un pipeline d'encodage vidéo MPEG-4 simplifié, couvrant l'ensemble des étapes depuis la conversion colorimétrique jusqu'à la compression entropique et la métrologie de qualité. Les résultats obtenus sont cohérents avec la théorie des codecs vidéo.

Les principaux enseignements sont les suivants :

- Le facteur de quantification QF est le levier le plus puissant pour contrôler le compromis taux/distorsion, avec un impact quasi-linéaire sur la compression et exponentiel sur la qualité.
- La structure GOP doit être adaptée au type de contenu : pour des vidéos à faible mouvement, les I-frames seules s'avèrent plus efficaces ; pour des vidéos dynamiques, un G plus grand exploiterait davantage la redondance temporelle.
- Un PSNR moyen de 40,8 dB avec QF=1 représente un excellent niveau de qualité pour un taux de compression de 41x, confirmant la pertinence des choix de conception.
- L'utilisation de zlib comme codage entropique, bien que plus simple qu'un codage Huffman adapté aux DCT, offre des performances solides sur les structures de données clairsemées issues de la quantification.

Des pistes d'amélioration possibles incluent : l'ajout de B-frames pour une meilleure exploitation de la redondance temporelle bidirectionnelle, le codage en zigzag des coefficients DCT avant la compression entropique, et l'utilisation d'un codage arithmétique adapté pour de meilleures performances que zlib.